Stream Processing 24/7

Real-Time Weather & Air Quality Monitoring Pipeline

Monitoraggio continuo di Meteo, Inquinamento e Rilevamento Anomalie con Kafka, PySpark, Machine Learning e Kibana.

OBIETTIVO PRIMARIO

Raccogliere ogni minuto i dati meteo di 12 capitali e grandi città europee, intercettare allarmi sanitari OMS in tempo reale ed identificare comportamenti atipici con algoritmi predittivi.

PANORAMICA DI SISTEMA

L’Architettura End-to-End in 5 Fasi

FASE 1

Raccolta Dati

Collector Node.js interroga le REST API gratuite di Open-Meteo per 12 città.

FASE 2

Buffer Kafka

Disaccoppiamento sicuro con coda di messaggistica ad altissima affidabilità.

FASE 3

Stream PySpark

Aggregazione live ogni 10 secondi e controllo soglie di allerta sanitaria OMS.

FASE 4

Spark MLlib

Clustering K-Means (k=3) su 7 feature e calcolo distanza anomalie.

FASE 5

Kibana Live

Dashboard interattiva con mappe geospaziali, grafici e notifiche di allarme.

Automazione Completa con Docker Compose

L'intero ecosistema (Broker, Cluster Spark, Elasticsearch, Kibana) si avvia con un singolo comando.

```
>_ docker compose up -d
```

FASI 1 & 2

Raccolta Dati & Coda Apache Kafka

Collector Node.js

Doppia API Open-Meteo in parallelo

- Cadenza a 60s: polling continuo su 12 metropoli europee.
- Payload unificato: fusione meteo e inquinanti (PM2.5, PM10, NO2, O3, AQI).
- Resilienza attiva: fallback automatico in caso di timeout esterno.

Buffer Apache Kafka

Disaccoppiamento & Partizionamento

- Nessuna perdita: assorbimento picchi tra sorgente e computazione.
- Canale Principale: topic dedicato .
  `weather_pollution.telemetry`
- Canali di Notifica: canali separati per Allarmi OMS e Anomalie ML.

12 Città europee monitorate simultaneamente

60s Frequenza di aggiornamento della telemetria

3 Topic Kafka dedicati allo smistamento

FASE 3

Elaborazione Stream & Allarmi OMS con PySpark

Micro-Batching ogni 10s

Elaborazione continua e ingestione in Elasticsearch.

Aggregazione per Città

Calcolo dinamico medie mobili di PM2.5, PM10 e temperatura.

Verifica Regole Sanitarie

Attivazione allarmi sanitari WARNING o CRITICAL.

Tabella Allarmi OMS in Diretta su Kibana LIVE

Allarmi Sanitari OMS (PM2.5 > 25 | PM10 > 50 | AQI > 50)

Città in Allarme	Livello Allerta	Picco PM2.5 (µg/m³)	Picco PM10 (µg/m³)	Picco AQI
Berlino	WARNING	32	48	61
Catania	WARNING	32	48	61
Firenze	WARNING	32	48	61
Milano	WARNING	32	48	61
Palermo	WARNING	32	48	61
Parigi	WARNING	32	48	61
Roma	WARNING	32	48	61
Napoli	WARNING	31.9	47.8	61

Rows per page: 10 1 2

Soglie di Sicurezza OMS: **PM2.5:** > 25 µg/m³ | **PM10:** > 50 µg/m³ | **Indice AQI:** > 50 (Livello Moderato / Critico)

FASE 4

Machine Learning: Clustering K-Means & Anomalie

Oltre le Soglie Fisse

Analisi congiunta su 7 dimensioni correlate (Temperatura, Umidità, Vento, PM2.5, PM10, NO2, AQI).

I 3 Profili K-Means

Cluster 0: Aria Pulita (ventilazione alta, basse polveri)

Cluster 1: Inquinamento Moderato (traffico urbano tipico)

Cluster 2: Inquinamento Critico (alta stagnazione e smog)

Rilevamento Anomalie

Se la distanza euclidea dal centroide del cluster supera la soglia di tolleranza (> 2.2), l'evento viene marcato come anomalia.

Distribuzione Cluster K-Means

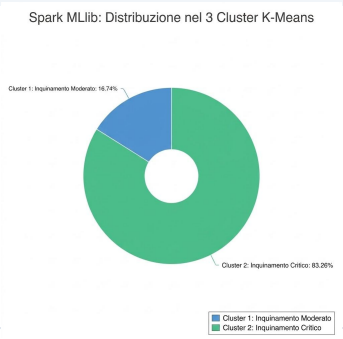


Tabella Live Anomaly Score & Valutazione

Bologna	Cluster 1: Inquinaramet...	true	7.308	26.35	13.75
Bologna	Cluster 1: Inquinararent...	false	2.169	18	13.521
Pelermo	Cluster 2: Inquinaramet...	true	2.609	27.907	14.307
Palermo	Cluster 2:	false	2.082	16.827	12.46

FASE 5 & VALUTAZIONE

Visualizzazione Live Kibana & Risultati

Mappa Geospaziale (12 Città Connesse)



Trend Storico Temporale in Tempo Reale



Setup Kibana Zero-Touch

Script automatico (`setup_kibana.py`) che genera indici, mapping e dashboard pronte all'uso.

Confronto & Sorveglianza

Controllo istantaneo delle città più a rischio smog con grafici comparativi di PM2.5 e PM10 aggiornati ogni minuto.

Conclusioni del Progetto

Pipeline robusta, scalabile e completamente containerizzata per l'analisi intelligente di big data ambientali.